

UM Projekt

Drzewo decyzyjne, które potrafi zmieniać się wskutek nadchodzenia nowych danych trenujących (uczenie przyrostowe).

Opis testów i wyników

Aby wykonać niżej opisane testy należy uruchomić skrypt o nazwie Test.py.

Liczenie dopasowania

Atrybuty ze zbioru testowego przechodzą przez węzły zgodnie z testami. Gdy dotrą do liści następuje liczenie dopasowania za pomocą poniższego równania.

$$\text{Dopasowanie} = Z/(Z+NZ)$$

Z – liczba elementów, dla których hipoteza była spójna z pojęciem docelowym

NZ - liczba elementów, dla których hipoteza nie była spójna z pojęciem docelowym

Im większe dopasowanie, tym algorytm dobiera lepszy zbiór hipotez, ponieważ więcej hipotez zgadza się z pojęciami docelowymi.

Test poprawności algorytmu odpowiedzialnego za budowę podstawowego drzewa

```
Budowa podstawowego drzewa dla danych od 20 do 40
{'no': 14, 'yes': 6}
test -0.39665561009259714 z kolumny 1
True:
{'no': 7, 'yes': 6}
test -0.8671450940660096 z kolumny 0
True:
{'no': 5, 'yes': 6}
test -0.016084581439933576 z kolumny 0
True:
{'no': 5, 'yes': 3}
test 0.34653211205010637 z kolumny 3
True:
{'yes': 2}
False:
{'no': 5, 'yes': 1}
test 1 z kolumny 37
True:
{'yes': 1}
False:
{'no': 5}
False:
{'yes': 3}
False:
{'no': 2}
False:
{'no': 7}
```

Rys. 1 Wynik budowy podstawowego drzewa

Test wykonano dla danych znajdujących się w pliku bank.csv (od 20 do 40). Uzyskane drzewo jest poprawne, poprawnie zostały dobrane testy i zgodnie z oczekiwaniami został wykonany podział danych.

Test poprawności algorytmu odpowiedzialnego za przyrostową naukę drzewa

```
Uczenie przyrostowe powyższego drzewa dla danych od 60 do 80
{'no': 33, 'yes': 7}
test -0.6425841750162897 z kolumny 3
True:
  {'no': 26, 'yes': 7}
  test -1.202325530181361 z kolumny 2
  True:
    {'no': 21, 'yes': 7}
    test -0.39665561009259714 z kolumny 1
    True:
      {'no': 13, 'yes': 6}
      test -0.8671450940660096 z kolumny 0
      True:
        {'no': 9, 'yes': 6}
        test 0.34653211205010637 z kolumny 3
        True:
          {'yes': 4}
        False:
          {'no': 9, 'yes': 2}
          test -0.2322470110835078 z kolumny 2
          True:
            {'no': 6, 'yes': 2}
            test 1 z kolumny 37
            True:
              {'yes': 1}
            False:
              {'no': 6, 'yes': 1}
              test 1 z kolumny 7
              True:
                {'yes': 1}
              False:
                {'no': 6}
          False:
            {'no': 3}
        False:
          {'no': 4}
      False:
        {'no': 8, 'yes': 1}
        test 1 z kolumny 40
        True:
          {'yes': 1}
        False:
          {'no': 8}
    False:
      {'no': 5}
  False:
    {'no': 7}
```

Rys. 2 Wynik douczenia drzewa z poprzedniego przykładu

Test wykonano dla danych znajdujących się w pliku bank.csv (od 60 do 80) i drzewa z poprzedniego punktu. Uzyskane drzewo jest poprawne, poprawnie zostały dobrane testy i zgodnie z oczekiwaniami został wykonany podział danych.

Zbiór „bank”

1 - age (numeric)

2 - job : type of job (categorical:
"admin.", "unknown", "unemployed", "management", "housemaid", "entrepreneur", "student",
"blue-collar", "self-employed", "retired", "technician", "services")

3 - marital : marital status (categorical: "married", "divorced", "single"; note: "divorced" means divorced or widowed)

4 - education (categorical: "unknown", "secondary", "primary", "tertiary")

5 - default: has credit in default? (binary: "yes", "no")

6 - balance: average yearly balance, in euros (numeric)

7 - housing: has housing loan? (binary: "yes", "no")

8 - loan: has personal loan? (binary: "yes", "no")

related with the last contact of the current campaign:

9 - contact: contact communication type (categorical: "unknown", "telephone", "cellular")

10 - day: last contact day of the month (numeric)

11 - month: last contact month of year (categorical: "jan", "feb", "mar", ..., "nov", "dec")

12 - duration: last contact duration, in seconds (numeric)

other attributes:

13 - campaign: number of contacts performed during this campaign and for this client (numeric, includes last contact)

14 - pdays: number of days that passed by after the client was last contacted from a previous campaign (numeric, -1 means client was not previously contacted)

15 - previous: number of contacts performed before this campaign and for this client (numeric)

16 - poutcome: outcome of the previous marketing campaign (categorical:
"unknown", "other", "failure", "success")

Output variable (desired target):

17 - y - has the client subscribed a term deposit? (binary: "yes", "no")

Utworzyć drzewo określające czy klient subskrybował lokatę terminową (możliwe wyniki y, n).

Zbiór „agaricus-lepiota”

1. cap-shape: bell=b, conical=c, convex=x, flat=f,
knobbed=k, sunken=s
2. cap-surface: fibrous=f, grooves=g, scaly=y, smooth=s
3. cap-color: brown=n, buff=b, cinnamon=c, gray=g, green=r,
pink=p, purple=u, red=e, white=w, yellow=y
4. bruises?: bruises=t, no=f
5. odor: almond=a, anise=l, creosote=c, fishy=y, foul=f,
musty=m, none=n, pungent=p, spicy=s
6. gill-attachment: attached=a, descending=d, free=f, notched=n
7. gill-spacing: close=c, crowded=w, distant=d
8. gill-size: broad=b, narrow=n
9. gill-color: black=k, brown=n, buff=b, chocolate=h, gray=g,
green=r, orange=o, pink=p, purple=u, red=e,
white=w, yellow=y
10. stalk-shape: enlarging=e, tapering=t
11. stalk-root: bulbous=b, club=c, cup=u, equal=e,
rhizomorphs=z, rooted=r, missing=?
12. stalk-surface-above-ring: fibrous=f, scaly=y, silky=k, smooth=s
13. stalk-surface-below-ring: fibrous=f, scaly=y, silky=k, smooth=s
14. stalk-color-above-ring: brown=n, buff=b, cinnamon=c, gray=g, orange=o,
pink=p, red=e, white=w, yellow=y
15. stalk-color-below-ring: brown=n, buff=b, cinnamon=c, gray=g, orange=o,
pink=p, red=e, white=w, yellow=y
16. veil-type: partial=p, universal=u
17. veil-color: brown=n, orange=o, white=w, yellow=y
18. ring-number: none=n, one=o, two=t
19. ring-type: cobwebby=c, evanescent=e, flaring=f, large=l,
none=n, pendant=p, sheathing=s, zone=z
20. spore-print-color: black=k, brown=n, buff=b, chocolate=h, green=r,
orange=o, purple=u, white=w, yellow=y
21. population: abundant=a, clustered=c, numerous=n,
scattered=s, several=v, solitary=y
22. habitat: grasses=g, leaves=l, meadows=m, paths=p,
urban=u, waste=w, woods=d


Utworzyć drzew, które na podstawie danych określa w jakim siedlisku występuje dany grzyb, możliwe wyniki grasses, leaves, meadows, paths, urban, waste, woods (pojęcie docelowe habitat).

Zbiór „iris”

1. sepal length in cm
2. sepal width in cm
3. petal length in cm
4. petal width in cm
5. class:
 - Iris Setosa
 - Iris Versicolour
 - Iris Virginica

Utworzyć drzewo, które na podstawie danych określa gatunek irisa (pojęcie docelowe class).

Współczynnik dopasowanie drzewa oryginalnego w zależności od ilości danych trenujących



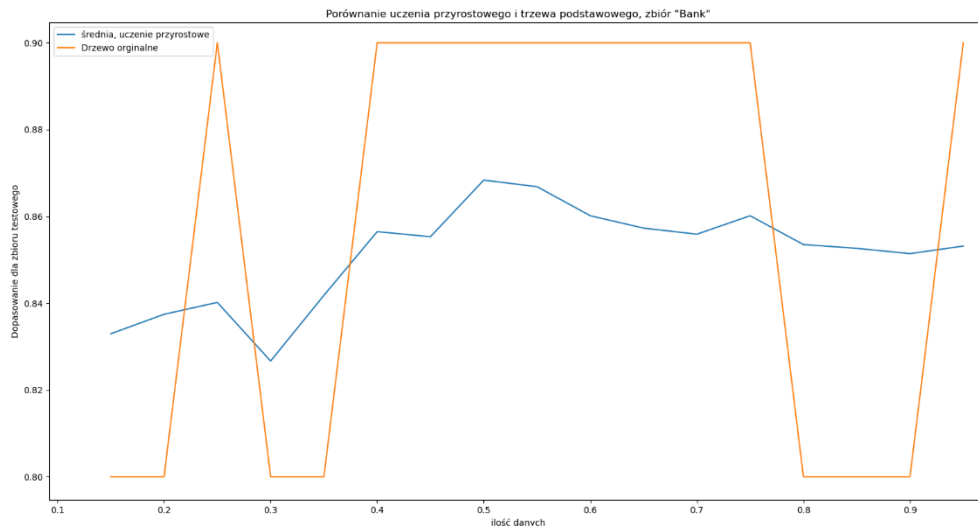
Rys. 3 Zależność dopasowania do zbioru testowego od ilości danych (na wykresie na osi x część użytych danych z całego zbioru treningowego, czyli cały zbiór danych bez danych użytych do testów)

Z przeprowadzonego badania wynika, że ilość danych użytych do trenowania nie ma wielkiego znaczenia. W dopasowaniu drzewa jakie można osiągnąć, bardzo ważne jest z jaką dziedziną pracuje algorytm, jeśli pomiędzy atrybutami występują niewielkie zależności, nie jesteśmy w stanie uzyskać drzewa o dużym dopasowaniu.

Porównanie algorytmu odpowiedzialnego za drzewo podstawowe i za uczenie przyrostowe

Średnia uczenia przyrostowego równa jest sumie uzyskanych dopasowań dla ilości danych w poszczególnych trenowaniach równych $n \cdot 0,05 \cdot (\text{ilości danych treningowych})$ i $1 - n \cdot 0,05 \cdot (\text{ilości danych treningowych})$, gdzie $n \in < 1, 19 >$, przez maksymalną wartość n (czyli 19).

Zbiór „bank”



Rys. 4 Zależność dopasowania do zbioru testowego od ilości danych dla drzewa oryginalnego i dla średniej wyników uzyskanych dla uczenia przyrostowego (na wykresie na osi x część użytych danych do trenowania z całego zbioru treningowego)

Uzyskane dopasowanie do zbioru testowego dla algorytmu uczenia przyrostowego dla większości badań jest niewiele mniejsze. Jest to spowodowane tym, że algorytm podstawowy szuka testów dla każdego węzła, dla których uzyskany zostanie najlepszy zysk informacji (miara pozwalająca wybrać atrybut, który najbardziej zminimalizuje ilość informacji niezbędnej do klasyfikacji przykładów w partycjach uzyskanych w wyniku podziału). Natomiast w algorytmie uczenia przyrostowego, aby zwiększyć jego szybkość, w pierwszej kolejności zostaje wybierany test ze starego drzewa dla odpowiedniego węzła, jeżeli uzyskany zostanie dla niego dobry zysk informacji.

Z powyższego badania wynika, że w niektórych sytuacjach dzięki algorytmowi uczenia przyrostowego można uzyskać lepsze dopasowanie. Z tego wynika, że nie zawsze warto wybierać test, który daje najlepszy zysk informacji (co ma miejsce w oryginalnym algorytmie). Drzewa budowane za pomocą algorytmu uczenia przyrostowego, dzięki wzorowaniu się na starym drzewie, dają dopasowania o mniejszych odchyleniach standardowego, w zależności od ilości danych użytych w poszczególnych trenowaniach. Algorytm uczenia przyrostowego daje większe szanse, że w wyniku douczania współczynnik dopasowania nie spadnie gwałtownie, jak może to mieć miejsce w algorytmie oryginalnym.

Tablice pomyłek

KP – Klasa predykowana

KR - Klasa rzeczywista

KP/KR	Klasa 1	Klasa 2	Klasa 3	Precyzja
Klasa 1	E_{11}	E_{21}	E_{31}	P_1
Klasa 2	E_{12}	E_{22}	E_{11}	P_2
Klasa 3	E_{13}	E_{21}	E_{32}	P_3
Czułość	C_1	C_2	C_3	

P_1 – precyzja dla predykcji klasa 1

$$P_1 = E_{11} / (E_{11} + E_{21} + E_{31})$$

C_1 – czułość dla pojęcia docelowego klasa 1

$$C_1 = E_{11} / (E_{12} + E_{11} + E_{13})$$

Algorytm podstawowy

Ilość danych w zbiorze treningowym = 0.95(ilość danych w całym zbiorze – ilość danych w zbiorze testowym).

Dokładność 0,85

KP/KR	no	yes	precyzja	1 – precyzja
no	743	75	0,9	0,1
yes	58	28	0,33	0,67
czułość	0,93	0,30		
1 – czułość	0,27	0,70		

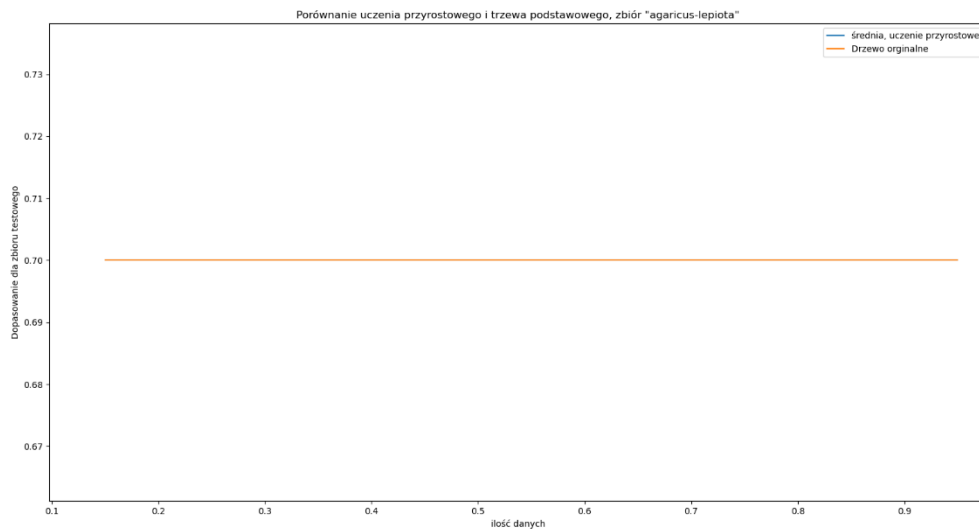
Algorytm uczenia przyrostowego

Ilość danych w zbiorze treningowym = 0.95(ilość danych w całym zbiorze – ilość danych w zbiorze testowym).

Dokładność 0,85

KP/KR	no	yes	precyzja	1 – precyzja
no	740	72	0,91	0,09
yes	61	31	0,34	0,66
czułość	0,93	0,30		
1 – czułość	0,27	0,70		

Zbiór „agaricus_incremental”



Rys. 5 Zależność dopasowania do zbioru testowego od ilości danych dla drzewa oryginalnego i dla średniej wyników uzyskanych dla uczenia przyrostowego (na wykresie na osi x część użytych danych z całego zbioru treningowego)

Z przeprowadzonego badania wynika, że dla niektórych danych mało ważna jest ilość danych i algorytm użyty do trenowania drzewa. Atrybuty opisujące dane pojęcia docelowe, mało różnią się od siebie, niezależnie od ilości danych i algorytmu tworzona jest podobna przestrzeń hipotez. Wiele przykładów z dziedziny musi być takich samych lub bardzo podobnych, przez co większa ilość danych treningowych nie wpływa znacząco na uzyskaną przestrzeń hipotez.

Algorytm podstawowy

Ilość danych w zbiorze treningowym = 0.95(ilość danych w całym zbiorze – ilość danych w zbiorze testowym).

Dokładność 0,70

KP/KR	u	g	m	p	d	precyzja	1 – precyzja
u	132	57	0	0	0	0,73	0,27
g	57	715	128	72	0	0,73	0,27
m	0	127	117	0	0	0,48	0,52
p	0	24	0	20	0	0,45	0,55
d	0	0	0	0	175	1	0
czułość	0,70	0,77	0,48	0,21	1		
1 – czułość	0,30	0,23	0,52	0,79	0		


Algorytm uczenia przyrostowego

Ilość danych w zbiorze treningowym = 0.95(ilość danych w całym zbiorze – ilość danych w zbiorze testowym).

Dokładność 0,70

KP/KR	u	g	m	p	d	precyzja	1 – precyzja
u	130	60	0	0	0	0,68	0,32
g	58	701	123	66	0	0,74	0,26
m	0	131	121	0	0	0,48	0,52
p	0	30	0	23	0	0,43	0,57
d	0	0	0	0	175	1	0
czułość	0,73	0,76	0,5	0,26	1		
1 – czułość	0,27	0,24	0,5	0,74	0		

Zbiór „iris”



Rys. 6 Zależność dopasowania do zbioru testowego od ilości danych dla drzewa oryginalnego i dla średniej wyników uzyskanych dla ucznia przyrostowego (na wykresie na osi x część użytych danych z całego zbioru treningowego)

Z powyższego badania wynika, że dla niektórych dziedzin jesteśmy w stanie uzyskać lepsze dopasowanie dla algorytmu ucznia przyrostowego niż dla algorytmu oryginalnego. Wynika z tego, że wybieranie za każdym razem testu, dla którego uzyskiwany jest najlepszy zysk informacji, nie prowadzi zawsze do uzyskania najlepszej przestrzeni hipotez. Jak widać wzorowanie się na starym drzewie w niektórych sytuacjach jest korzystne.

Algorytm podstawowy

Ilość danych w zbiorze treningowym = 0.95(ilość danych w całym zbiorze – ilość danych w zbiorze testowym).

Dokładność 0,87

KP/KR	Iris-setosa	Iris-versicolor	Iris-virginica	precyzja	1 – precyzja
Iris-setosa	7	0	0	1	0
Iris-versicolor	0	12	0	1	0
Iris-virginica	0	4	7	0,64	0,36
czułość	1	0,75	1		
1 – czułość	0	0,25	0		


Algorytm uczenia przyrostowego

Ilość danych w zbiorze treningowym = 0.95(ilość danych w całym zbiorze – ilość danych w zbiorze testowym).

Dokładność 0,90

KP/KR	Iris-setosa	Iris-versicolor	Iris-virginica	precyzja	1 – precyzja
Iris-setosa	7	0	0	1	0
Iris-versicolor	0	13	0	1	0
Iris-virginica	0	3	7	0,64	0,36
czułość	1	0,81	1		
1 – czułość	0	0,19	0		


Złożoność czasowa algorytmu podstawowego



Rys. 7 Zależność czasu trwania algorytmu od ilości danych (na wykresie na osi x część użytych danych z całego zbioru treningowego, czyli cały zbiór danych bez danych użytych do testów)

Z powyższego badania wynika, że im większy zbiór treningowy został wykorzystany do trenowania, tym czas trwania algorytmu jest dłuższy. Jeżeli więcej danych przetwarza dany algorytm, czas się wydłuża, ponieważ więcej operacji musi wykonać komputer podczas obliczeń.

Złożoność czasowa algorytmu uczenia przyrostowego



Rys. 8 Zależność czasu trwania algorytmu od ilości danych wykorzystanych w poszczególnych trenowaniach (na wykresie na osi x część użytych danych z całego zbioru treningowego odpowiednio do trenowania podstawowego i do uczenia przyrostowego), wykres pomarańczowy do uczenia przyrostowego użyto oryginalnego algorytmu, wykres niebieski użyto algorytm uczenia przyrostowego.

Z przedstawionego badania wynika, że dla dziedziny, w której znajdują się wiele przykładów takich samych lub bardzo podobnych do siebie, lepszy jest do dotrenowania algorytm podstawowy. Uzyskiwane jest takie samo dopasowanie, a czas trenowania jest znacznie krótszy. Algorytm podstawowy szuka testu, który daje największy zysk informacji, dzięki temu, gdy dane pozwalają uzyskać mało liczną przestrzeń hipotez, czas jego wykonywania jest krótki. Algorytm uczenia przyrostowego wykonuje sprawdzenia, czy coś można wykorzystać ze starego drzewa, co jest dłuższe niż zbudowanie węzła od nowa, dla dziedziny z atrybutami opisującymi dane pojęcia docelowe, mało różniącymi się od siebie.

Dla dziedziny, w której nie znajdują się wiele przykładów takich samych lub bardzo podobnych do siebie, algorytm uczenia przyrostowego okazał się szybszy, w takich sytuacjach korzystniejsze jest wzorowanie się na starym drzewie. Mniej czasochłonne jest sprawdzenie, czy można coś wykorzystać ze starego drzewa niż szukać od nowa testów.

Podsumowanie

Używanie algorytmu uczenia przyrostowego w większości przypadków, daje niewiele gorsze dopasowanie, ale w niektórych przypadkach jest znacznie szybszy.

Kiedy nie warto używać algorytmu uczenia przyrostowego:

- dla dziedzin w których znajdują się wiele przykładów takich samych lub bardzo podobnych do siebie

W przeciwnych wypadkach lepiej używać algorytmu uczenia przyrostowego, czas wykonywania jest zazwyczaj krótszy a dopasowanie podobne.

Do wyboru algorytmu uczenia przyrostowego lub oryginalnego algorytmu należy podchodzić indywidualnie, w zależności od rodzaju danych, ilości danych. Warto przed trenowaniem całym zbiorem treningowym, zrobić testy na małej dziedzinie, alby sprawdzić czas wykonywania i dopasowanie jakie daje algorytm.

W celu przyspieszenia algorytmu uczenia przyrostowego zastosowano następujące uproszczenia:

- Sprawdzenie czy dane w danym węźle nie występowały w którymś z węzłów stawnego drzewa, jeżeli tak następuje kopiowanie poddrzewa

- Jeżeli dla testu względem której został dokonany podział, z węzła starego drzewa jesteśmy w stanie uzyskać dobry zysk informacji, następuje podział według tego testu. Dzięki temu nie trzeba sprawdzać jaki zysk informacji można uzyskać dla każdego możliwego testu, które jest dosyć czasochłonne dla dużej ilości danych, ale możemy uzyskać trochę gorszą hipotezę niż byłoby to możliwe.

- Jeżeli przez test ze starego drzewa zostanie uzyskany tylko o 0,1 gorszy zysk informacji niż dla najlepszego z możliwych testów, zostaje wybrane stary test (zwiększa to szanse, że w kolejnych węzłach zostaną wykorzystane poddrzewa ze starego drzewa)

- Jeżeli, żaden z powyższych warunków nie został spełniony, to węzeł jest budowany od nowa (bez wzorowania się na starym drzewie).

Opis plików

Build.py - plik z algorytmem budowy podstawowego drzewa

Incremental_learning.py - plik z algorytmem uczenia przyrostowego

Measure.py - plik z funkcjami obliczającymi współczynniki (zysku informacji itp.)

Split.py - plik z funkcjami dokonującymi podziału danych

Print_tree.py - plik z funkcjami do wypisania drzewa

Data.py - plik z funkcją wczytującą dane

Correctness_of_building.py - plik z funkcjami do testów

Data_matching.py - plik z funkcjami do testów dopasowania

Test.py - plik z funkcją wywołującą testy

Alby uruchomić projekt należy zainstalować poniższe biblioteki

- sklearn-learn

Instalacja: pip install -U scikit-learn

- pandas

Instalacja: pip install pandas

Zakończenie

Czego nauczyłem się dzięki realizacji projektu:

- podstaw języka python
- podstaw bibliotek numpy, pandas i sklearn-learn
- drzew decyzyjnych
- pracy nad własnymi algorytmami
- pracy nad zwiększeniem szybkości algorytmu
- testowanie algorytmów
- dzięki projektowi zainteresowałem się bardziej uczeniem maszynowym i zacząłem uczyć się biblioteki sklearn-learn i planuję w przyszłości tensorflow

Algorytm uczenia przyrostowego i budowy podstawowego drzewa jest uniwersalny, należy jedynie zadbać, aby pojęcia docelowe, podczas terowania znajdowały się w ostatniej kolumnie.

Dokumentacja kodu znajduje się w pliku „dokumentacja końcowa - doxygen.pdf”